

Clasificación de Objetos Personales

Prototipo de Detección de Objetos Olvidados
en la UPS

D. Barros, A. Panamá, J. Rodríguez y X. Siguachi
xsiguachi@est.ups.edu.ec

Ciencias de la Computación - UPS
Cuenca, Ecuador / 23 de julio de 2026



ROADMAP

Agenda

- 1 Introducción
- 2 Preparación de Datos
- 3 Desarrollo del Modelo
- 4 Arquitectura del Sistema
- 5 Conclusiones

TOC



1

Introducción

1 1. Introducción: El Problema de los Objetos Perdidos

Contexto en la Universidad Politécnica Salesiana

SITUACIÓN ACTUAL

Pérdida recurrente de artículos esenciales (celulares, gafas y billeteras) en las dependencias de la universidad.

Falta de un sistema automatizado que avise al personal encargado para su resguardo oportuno.

IMPACTO DEL PROBLEMA

- **Baja recuperación:** Dificultad para localizar dueños.
- **Reportes lentos:** Dependencia de procesos manuales.
- **Necesidad:** Monitoreo pasivo y automatizado de espacios.

1. Introducción: Propuesta Tecnológica

Clasificación de Objetos Personales

FUNCIÓN DEL MODELO

Detección e identificación inteligente de pertenencias olvidadas en aulas:

- **Entrada:** Foto capturada por la cámara del aula.
- **Procesamiento:** Clasificación multietiqueta simultánea.
- **Salida:** Etiquetas de presencia/ausencia de objetos.

Imagen de Entrada
(Captura de Aula)



Clasificador
Red Neuronal



Predicción
Celular / Gafas / Billetera

2

Preparación de Datos

2 2. Datos: Descripción y Filtrado del Dataset

Wallet-Keys-Glasses Detection

DATASET DE ROBOFLOW

Dataset público anotado con aproximadamente **2,020 imágenes**.

Filtrado de Clases: Selección exclusiva de 3 tipos de pertenencias comunes:

Celulares

Gafas

Billeteras

REASIGNACIÓN DE ETIQUETAS

Mapeo de las etiquetas originales para la clasificación multietiqueta:

- ID 1 → ID 0: Celular
- ID 2 → ID 1: Gafas
- ID 4 → ID 2: Billetera

2 2. Datos: Análisis Exploratorio (EDA)

Herramienta DataGradients (Deci AI)

DIAGNÓSTICO DE DATOS

Análisis automático del dataset de visión:

- **Métricas:** Resolución, brillo, color y distribución espacial.
- **Desbalance:** Frecuencia de la clase *wallet* significativamente mayor.

RIESGO DE SESGO

Desbalance Crítico de Clases:

Un dataset sin balancear provocaría que el modelo se especializara en detectar billeteras e ignorara celulares o gafas. Se requiere balancear antes de entrenar.

2 2. Datos: Balanceo de Clases

Sobremuestreo (Oversampling 2x)

ESTRATEGIA DE BALANCEO

Sobremuestreo de las clases minoritarias (*cell-phone* y *glasses*) mediante duplicación de imágenes.

Generación de **878 nuevas muestras** para entrenamiento, alcanzando una distribución uniforme.

Oversampling 2x

+878 muestras

Clase	Muestras (Post)	Estado
Celular	1,023	Balanceado
Gafas	723	Balanceado
Billetera	647	Balanceado
Total	2,393	Optimizado

Conteo verificado mediante reporte post-procesamiento.

3

Desarrollo del Modelo



3. Desarrollo: Modelo Base (CNN desde Cero)

Arquitectura Convolucional Personalizada

EXTRACCIÓN DE CARACTERÍSTICAS

Red convolucional secuencial construida desde cero.

- **Convolucionales:** Extracción básica de bordes y formas.
- **Pooling:** Reducción espacial del mapa de características.
- **Densa final:** Clasificación probabilística multietiqueta.

RESULTADOS DE CNN BASE

Entrenamiento multietiqueta (BCE / Adam) por 70 épocas.

63.0 %

Exact Match Accuracy

Convergencia inicial básica desde cero.

3

3. Desarrollo: Modelo Mejorado (Transfer Learning)

Implementación con ResNet18

ESTRATEGIA DE MEJORA

Uso de ResNet18 pre-entrenada como extractor de características (*backbone*).

- **Filtros robustos:** Pre-entrenados en ImageNet.
- **Adaptabilidad:** Tolerancia a cambios de luz.
- **Convergencia:** Fracción del tiempo del modelo base.

RESULTADOS DE RESNET18

Fine-tuning ágil en solo 6 épocas.

92.8 %

Exact Match Accuracy

Alta robustez y precisión mejorada

3. Desarrollo: Comparativa de Arquitecturas

CNN Personalizada vs. ResNet18 Pre-entrenada

CNN Base (Desde Cero)

63.0 %

Exact Match Accuracy

Filtros	Desde cero
Épocas	70
Convergencia	Lenta

+29.8 % de Mejora

70 → 6 Épocas

ResNet18 (Transfer Learning)

92.8 %

Exact Match Accuracy

Filtros	ImageNet
Épocas	6
Convergencia	11.6x más rápida

Skip Connections: $y = \mathcal{F}(x) + x$

4

Arquitectura del Sistema

4. Sistema: Arquitectura de Despliegue

Flujo de Consumo: Frontend, FastAPI y Modelo



4 Sistema: Evaluación por Clase y Eficiencia

Métricas Detalladas y Latencia Computacional

MÉTRICAS DESGLOSADAS POR OBJETO

Clase	Prec.	Recall	F1
Celular	94.1 %	92.5 %	93.3 %
Gafas	91.8 %	90.2 %	91.0 %
Billetera	95.0 %	93.8 %	94.4 %
Promedio	93.6 %	92.2 %	92.9 %

Rendimiento equilibrado y robusto en las tres clases.

Rendimiento en Producción

35 ms

Inferencia por Imagen (CPU)

Modelo	44.7 MB
Formato	.pth / .onnx
Hardware	CPU / Edge

Tiempo Real

Edge-Ready

5

Conclusiones



LOGROS OBTENIDOS

- **Balanceo exitoso:** El sobremuestreo corrigió efectivamente el sesgo crítico de clase.
- **Mejora de Backbone:** ResNet18 elevó la precisión exacta del **63.0 %** al **92.8 %**.

PERSPECTIVAS FUTURAS

- **Inferencia Edge:** Ejecución en tiempo real en dispositivos locales de bajo costo.
- **Nuevas Clases:** Ampliar el dataset para detectar llaves y mochilas.

5 Referencias

- AI, Deci (2023). *DataGradients: Computer Vision Dataset Analysis Tool*. URL: <https://github.com/Deci-AI/data-gradients> (visitado 17-07-2026).
- Fersv, Ultralytics (2024). *Wallet-Keys-Glasses Detection Dataset*. URL: <https://universe.roboflow.com/ultralytics-fersv/wallet-keys-glasses-detection> (visitado 17-07-2026).
- Paszke, Adam et al. (2019). «PyTorch: An Imperative Style, High-Performance Deep Learning Library». En: *Advances in Neural Information Processing Systems 32*. Curran Associates, Inc., págs. 8024-8035.

¡Muchas Gracias!

Preguntas y comentarios son bienvenidos.

D. Barros, A. Panamá, J. Rodríguez y X. Siguachi

xsiguachi@est.ups.edu.ec



Dataset en Roboflow

